

**BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC QUY NHƠN**



BÁO CÁO ĐỒ ÁN

**ĐỀ TÀI: PHÂN TÍCH XU HƯỚNG VÀ DỰ BÁO GIÁ BẤT
ĐỘNG SẢN TẠI BÌNH ĐỊNH GIAI ĐOẠN 2026.**

Nhóm thực hiện:	Nhóm 1
Lớp sinh viên:	Khoa học dữ liệu K46
Khóa:	46
Mã học phần:	252101042901
Hướng dẫn:	Ts. Cao Tấn Bình Anh Bùi Đức Lực

– Tháng 6/2026–

DANH SÁCH THÀNH VIÊN NHÓM

STT	TÊN SINH VIÊN	MSSV	Đóng góp
1	Cao Thị Hân	4654110006	Phân tích EDA
2	Huỳnh Thanh Trà	4654110013	Viết báo cáo
3	Trần Thị Diệu Trinh	4654110014	Trưởng nhóm/ Báo cáo: -Hỗ trợ các thành viên hoàn thành nhiệm vụ - Scraping dữ liệu -Làm PPT
4	Võ Kiều Trinh	4654110015	Feature Engineering & Xây dựng mô hình
5	Lê Thị Phụng	4654110019	Tiền xử lí dữ liệu

MỤC LỤC

CHƯƠNG I. LỜI CẢM ƠN	1
CHƯƠNG II. TỔNG QUAN ĐỀ TÀI	2
1. Lý do chọn đề tài	2
2. Mục tiêu nghiên cứu	2
3. Phạm vi nghiên cứu	3
4. Quy trình thực hiện đề tài	3
CHƯƠNG III. THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU	5
1. Nguồn dữ liệu	5
2. Thu thập dữ liệu bằng kỹ thuật Web Scraping	5
3. Tiền xử lý dữ liệu.....	8
4. Kết quả dữ liệu sau khi xử lý.....	12
CHƯƠNG IV. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU VÀ ĐẶC TRƯNG THỊ TRƯỜNG BẤT ĐỘNG SẢN BÌNH ĐỊNH	14
1. Phân tích thống kê phân phối giá và cấu trúc thị trường bất động sản bình định.....	14
2. Phân tích ma trận tương quan và mối quan hệ giữa các biến đặc trưng	17
3. Phân tích phân bố giá bất động sản theo không gian địa lý.....	18
4. Phân tích mật độ tin đăng, tác động của pháp lý và hướng bất động sản đến giá trị tài sản	20
CHƯƠNG V. XÂY DỰNG, HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH DỰ ĐOÁN GIÁ BẤT ĐỘNG SẢN.....	25
1. Mở đầu và Thiết lập Môi trường Lập trình.....	25
2. Xác định Biến mục tiêu (Target Variable Y).....	25
3. Kỹ thuật Đặc trưng Nâng cao (Advanced Feature Engineering)	26
4. Pipeline Tiền xử lý Dữ liệu Sạch (Preprocessing Pipeline).....	27
5. Huấn luyện Mô hình Baseline (Cross-Validation 5-Fold).....	27
6. Xác định và Trực quan hóa Tầm quan trọng của Đặc trưng.....	28
7. Tối ưu hóa với GridSearchCV (Giảm thiểu Overfitting).....	28
8. Xây dựng Mô hình Random Forest Tối ưu và Dự đoán thực tế	29
9. Đồ thị Chẩn đoán và Bảng so sánh Hiệu năng Tổng hợp	29
CHƯƠNG VI. KẾT LUẬN	30
PHỤ LỤC	34

CHƯƠNG I. LỜI CẢM ƠN

Lời đầu tiên, nhóm thực hiện dự án xin được gửi lời cảm ơn chân thành và sâu sắc nhất đến Khoa Toán Thống kê – Trường Đại học Quy Nhơn cùng các thầy cô bộ môn ngành Khoa học Dữ liệu. Trong suốt thời gian qua, Khoa đã luôn tạo điều kiện tốt nhất về môi trường học tập, cơ sở vật chất và cung cấp những nền tảng kiến thức lý thuyết vững chắc, giúp chúng em có đủ tự tin để thực hiện đề tài thực tiễn này.

Chúng em xin bày tỏ lòng biết ơn vô hạn tới Giảng viên hướng dẫn Ts Cao Tấn Bình, người đã trực tiếp theo sát, tận tình chỉ bảo và đưa ra những phản hồi chuyên môn quý báu trong suốt lộ trình 10 ngày làm việc của nhóm. Những góp ý của Thầy về phương pháp thu thập dữ liệu, phân tích EDA và tinh chỉnh mô hình Machine Learning không chỉ giúp dự án hoàn thiện đúng tiến độ mà còn giúp chúng em hiểu sâu sắc hơn về quy trình làm việc thực tế.

Đặc biệt, nhóm xin gửi lời cảm ơn chân thành đến Ban lãnh đạo cùng Mentor Bùi Đức Lực tại Công ty TMA Solutions. Sự đồng hành và hỗ trợ từ phía công ty đã tạo cơ hội cho chúng em được tiếp cận với môi trường làm việc chuyên nghiệp, được học hỏi từ những kinh nghiệm thực chiến của các chuyên gia trong ngành. Nhờ sự hướng dẫn của các anh Mentor, nhóm đã có thêm những góc nhìn thực tế về cách xử lý dữ liệu thô, vượt qua các rào cản kỹ thuật khi scraping và tối ưu hóa mô hình dự báo.

Dự án này là kết quả của quá trình nỗ lực học hỏi, làm việc nhóm nghiêm túc thông qua các công cụ hiện đại như GitHub, Jupyter Notebook và các thuật toán học máy. Mặc dù đã cố gắng hoàn thiện dự án với kết quả $R^2 \geq 0.75$ như mục tiêu đề ra, nhưng do kiến thức và thời gian có hạn, báo cáo chắc chắn không tránh khỏi những thiếu sót. Chúng em rất mong nhận được những ý kiến đóng góp từ quý Thầy và các chuyên gia để dự án ngày càng hoàn thiện hơn.

Một lần nữa, chúng em xin kính chúc quý Thầy/Cô Khoa Toán Thống kê, Ban lãnh đạo cùng các anh/chị tại Công ty TMA Solutions luôn dồi dào sức khỏe và gặt hái được nhiều thành công trong sự nghiệp cao quý của mình.

Trân trọng cảm ơn!

Quy Nhơn, ngày 05 tháng 06 năm 2026

Nhóm thực hiện dự án (Nhóm 1)

CHƯƠNG II. TỔNG QUAN ĐỀ TÀI

1. Lý do chọn đề tài

Thị trường bất động sản là một trong những lĩnh vực có vai trò quan trọng đối với sự phát triển kinh tế - xã hội của mỗi địa phương. Giá trị bất động sản chịu tác động đồng thời của nhiều yếu tố như vị trí địa lý, diện tích, loại hình tài sản, cơ sở hạ tầng, điều kiện pháp lý và mức độ phát triển kinh tế của khu vực. Do đó, việc xác định giá trị thực của bất động sản luôn là một bài toán phức tạp đối với nhà đầu tư, doanh nghiệp môi giới cũng như người dân có nhu cầu mua bán nhà đất.

Trong những năm gần đây, tỉnh Bình Định nói chung và thành phố Quy Nhơn nói riêng đã chứng kiến tốc độ đô thị hóa nhanh chóng cùng với sự phát triển mạnh mẽ của hệ thống giao thông, du lịch và các khu đô thị mới. Sự thay đổi này kéo theo những biến động đáng kể về giá bất động sản giữa các khu vực trong tỉnh. Tuy nhiên, phần lớn các quyết định định giá hiện nay vẫn dựa trên kinh nghiệm cá nhân hoặc khảo sát thủ công, dẫn đến nhiều hạn chế về tính khách quan và độ chính xác.

Sự phát triển của Khoa học dữ liệu, Khai phá dữ liệu và Trí tuệ nhân tạo đã mở ra khả năng ứng dụng các phương pháp phân tích dữ liệu hiện đại vào lĩnh vực bất động sản. Thông qua việc thu thập, xử lý và phân tích dữ liệu từ các nền tảng giao dịch trực tuyến, các mô hình học máy có thể hỗ trợ dự đoán giá bất động sản một cách nhanh chóng và hiệu quả hơn.

Xuất phát từ thực tiễn đó, đề tài **“Phân tích và dự đoán giá bất động sản ở Quy Nhơn và các huyện lân cận thuộc tỉnh Bình Định”** được thực hiện nhằm khai thác dữ liệu bất động sản thực tế, phân tích các đặc điểm của thị trường địa phương và xây dựng mô hình dự đoán giá dựa trên các kỹ thuật Khoa học dữ liệu.

2. Mục tiêu nghiên cứu

a. Mục tiêu tổng quát

Nghiên cứu đặc điểm thị trường bất động sản tại thành phố Quy Nhơn và các địa phương lân cận thuộc tỉnh Bình Định, đồng thời xây dựng mô hình dự đoán giá bất động sản dựa trên các phương pháp học máy.

b. Mục tiêu cụ thể

- Thu thập dữ liệu bất động sản từ các nguồn trực tuyến thông qua kỹ thuật Web Scraping.
- Xây dựng bộ dữ liệu bất động sản phục vụ cho quá trình phân tích và mô hình hóa.
- Thực hiện tiền xử lý dữ liệu, làm sạch dữ liệu và xây dựng các biến đặc trưng cần thiết.
- Phân tích khám phá dữ liệu nhằm nhận diện đặc điểm phân bố giá và các yếu tố ảnh hưởng đến giá bất động sản.
- Đánh giá mức độ tác động của các biến như diện tích, vị trí, loại hình bất động sản, số tầng, số phòng ngủ, pháp lý và hướng nhà đối với giá trị tài sản.
- Xây dựng các mô hình Ridge Regression và Random Forest dự đoán giá bất động sản

- So sánh hiệu quả giữa các mô hình bằng các tham số RMSE và R^2 và lựa chọn mô hình phù hợp nhất cho bài toán dự đoán giá.

3. Phạm vi nghiên cứu

a. Phạm vi không gian

Nghiên cứu được thực hiện trên dữ liệu bất động sản thuộc địa bàn tỉnh Bình Định, tập trung chủ yếu tại:

- Thành phố Quy Nhơn
- Thị xã An Nhơn
- Huyện Tuy Phước
- Huyện Phù Cát
- Thị xã Hoài Nhơn
- Huyện Vân Canh
- Huyện Phù Mỹ

b. Phạm vi dữ liệu

Dữ liệu nghiên cứu được thu thập từ các nền tảng đăng tin bất động sản trực tuyến, bao gồm các thông tin như:

- Giá bất động sản
- Diện tích
- Chiều ngang mặt tiền
- Chiều sâu thửa đất
- Loại hình bất động sản
- Địa chỉ
- Số tầng
- Số phòng ngủ
- Số nhà vệ sinh
- Tình trạng pháp lý
- Hướng bất động sản

c. Phạm vi nội dung

Đề tài tập trung vào việc phân tích đặc điểm thị trường và dự đoán giá bất động sản, không đi sâu vào các yếu tố pháp lý, quy hoạch chi tiết hoặc thẩm định giá theo tiêu chuẩn chuyên ngành bất động sản.

4. Quy trình thực hiện đề tài

Quy trình thực hiện đề tài được xây dựng theo các bước chính sau:

Bước 1: Thu thập dữ liệu

Tiến hành thu thập dữ liệu bất động sản từ các website đăng tin trực tuyến bằng kỹ thuật Web Scraping.

Bước 2: Tiền xử lý dữ liệu

Thực hiện làm sạch dữ liệu, loại bỏ các bản ghi trùng lặp, xử lý dữ liệu thiếu và chuẩn hóa định dạng dữ liệu.

Bước 3: Phân tích khám phá dữ liệu

Tiến hành thống kê mô tả, trực quan hóa dữ liệu và phân tích mối quan hệ giữa các biến nhằm hiểu rõ đặc điểm của thị trường bất động sản.

Bước 4: Xây dựng đặc trưng

Tạo các biến mới và lựa chọn các đặc trưng phù hợp phục vụ cho quá trình huấn luyện mô hình.

Bước 5: Xây dựng mô hình dự đoán

Áp dụng các thuật toán học máy để xây dựng mô hình Ridge Regression và Random Forest dự đoán giá bất động sản.

Bước 6: Đánh giá mô hình

Sử dụng các chỉ số đánh giá như RMSE và R^2 để đo lường hiệu quả của các mô hình.

Bước 7: Kết luận và đề xuất

Tổng hợp kết quả nghiên cứu, đưa ra nhận xét, đánh giá và đề xuất hướng phát triển trong tương lai.

CHƯƠNG III. THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU

1. Nguồn dữ liệu

Dữ liệu là nền tảng cốt lõi quyết định chất lượng của mọi mô hình phân tích và dự đoán trong lĩnh vực khoa học dữ liệu. Đối với bài toán nghiên cứu thị trường bất động sản Bình Định, hiện nay chưa tồn tại một bộ dữ liệu công khai hoàn chỉnh chứa đầy đủ thông tin về giá bán, diện tích, vị trí địa lý, đặc điểm xây dựng và tình trạng pháp lý của các bất động sản trên địa bàn tỉnh. Do đó, nhóm nghiên cứu lựa chọn phương pháp thu thập dữ liệu trực tiếp từ các nền tảng giao dịch bất động sản trực tuyến đang hoạt động phổ biến tại Việt Nam.

Hai nguồn dữ liệu chính được sử dụng trong đề tài gồm:

- <https://alonhadat.com.vn/can-ban-nha-dat/binh-dinh>
- <https://batdongsan.com.vn/nha-dat-ban-binh-dinh>

Đây là hai website có số lượng tin đăng lớn, liên tục được cập nhật bởi các cá nhân, môi giới và doanh nghiệp kinh doanh bất động sản trên toàn quốc. Các nền tảng này cung cấp nhiều thông tin quan trọng liên quan đến tài sản được rao bán như giá bán, diện tích, địa chỉ, hướng nhà, pháp lý, số tầng, số phòng ngủ, số nhà vệ sinh và mô tả chi tiết về bất động sản.

Phạm vi nghiên cứu được giới hạn trong các tin đăng thuộc địa bàn tỉnh Bình Định, bao gồm Thành phố Quy Nhơn và các huyện, thị xã lân cận như An Nhơn, Tuy Phước, Phù Cát, Hoài Nhơn, Vân Canh và Phù Mỹ. Việc giới hạn phạm vi địa lý giúp đảm bảo tính đồng nhất của dữ liệu cũng như phản ánh đúng đặc điểm của thị trường bất động sản địa phương.

2. Thu thập dữ liệu bằng kỹ thuật Web Scraping

a. Lựa chọn phương pháp thu thập dữ liệu

Trong bối cảnh dữ liệu bất động sản được công bố chủ yếu dưới dạng các trang web động, việc nhập liệu thủ công không những tốn nhiều thời gian mà còn dễ phát sinh sai sót. Để giải quyết vấn đề này, đề tài sử dụng kỹ thuật Web Scraping nhằm tự động hóa quá trình thu thập dữ liệu từ các website bất động sản.

Web Scraping là quá trình sử dụng các chương trình máy tính để truy cập trang web, đọc nội dung HTML và trích xuất các thông tin cần thiết thành dữ liệu có cấu trúc. Phương pháp này cho phép thu thập số lượng lớn dữ liệu trong thời gian ngắn, đồng thời đảm bảo tính nhất quán của bộ dữ liệu.

Trong quá trình triển khai, nhóm nghiên cứu nhận thấy nhiều website bất động sản hiện nay sử dụng các cơ chế chống bot như Cloudflare, JavaScript Rendering hoặc Captcha nhằm ngăn chặn việc truy cập tự động. Vì vậy, thay vì sử dụng thư viện Requests truyền thống, đề tài sử dụng Selenium kết hợp với Undetected ChromeDriver để mô phỏng hành vi của người dùng thực trên trình duyệt.

b. Công cụ sử dụng

i) Selenium và Undetected ChromeDriver

Selenium là thư viện hỗ trợ điều khiển trình duyệt tự động. Công cụ này cho phép chương trình mô phỏng các thao tác của người dùng như truy cập website, nhấn nút, cuộn trang hoặc lấy nội dung HTML sau khi JavaScript đã được thực thi.

Undetected ChromeDriver là phiên bản mở rộng của ChromeDriver giúp giảm khả năng bị phát hiện bởi các hệ thống chống bot. Thư viện này cho phép trình duyệt hoạt động gần giống với người dùng thực, từ đó nâng cao tỷ lệ thu thập dữ liệu thành công.

```
def init_driver():
    options = uc.ChromeOptions()
    options.add_argument('--start-maximized')
    options.add_argument('--disable-gpu')
    options.add_argument('--user-agent=Mozilla/5.0 (Windows NT 10.0; Win64; x64)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/122.0.0.0 Safari/537.36')
    driver = uc.Chrome(options=options, version_main=148)
    return driver
```

Đoạn mã trên cho phép chương trình khởi tạo trình duyệt Chrome với User-Agent tương tự người dùng thật, hạn chế nguy cơ bị website chặn trong quá trình thu thập dữ liệu.

ii) *BeautifulSoup*

BeautifulSoup được sử dụng để phân tích cú pháp HTML và trích xuất thông tin từ các thẻ HTML. Sau khi Selenium tải xong nội dung trang web, BeautifulSoup sẽ hỗ trợ tìm kiếm các thành phần chứa dữ liệu cần thiết như tiêu đề, giá bán, diện tích và địa chỉ.

```
soup = BeautifulSoup(driver.page_source, 'html.parser')
```

iii) *Pandas*

Pandas được sử dụng để lưu trữ và xử lý dữ liệu dưới dạng DataFrame. Đây là thư viện quan trọng giúp thực hiện các thao tác làm sạch, chuyển đổi và chuẩn hóa dữ liệu trước khi đưa vào phân tích.

c. *Xử lý cơ chế chống bot*

Một trong những khó khăn lớn khi thu thập dữ liệu từ các website bất động sản là sự xuất hiện của các hệ thống chống truy cập tự động như Cloudflare.

Để phát hiện và xử lý tình huống này, chương trình sử dụng hàm kiểm tra nội dung trang web:

```
def check_and_wait_for_captcha(driver):
    while True
        soup = BeautifulSoup(driver.page_source, 'html.parser')
        page_title = driver.title.lower
        page_text = soup.text.lower()
        is_blocked = (
            "vui lòng thử lại sau" in page_text or
            "truy cập quá nhiều" in page_text or
            "cloudflare" in page_title or
            "just a moment" in page_title
        )

        if is_blocked:
```

```

print("\n" + "!"*60)
print(" 🚨 CẢNH BÁO: HỆ THỐNG ĐANG KHÓA IP HOẶC YÊU CẦU XÁC THỰC!")
print(" 📶 BẬT 4G/5G ĐIỆN THOẠI -> PHÁT WIFI CHO MÁY TÍNH ĐỂ ĐỔI IP MỚI.")
print(" 🔄 Kiểm tra trình duyệt xem danh sách nhà đất đã tải lại bình thường chưa.")
print("!"*60 + "\n")
input("Nhấn phím [ENTER] tại đây để TIẾP TỤC chạy lại sau khi đã đổi mạng...")
driver.refresh()
time.sleep(5)
else:
    break

```

Thông qua việc kiểm tra tiêu đề và nội dung trang web, chương trình có thể xác định các trường hợp bị Cloudflare chặn để thực hiện các biện pháp xử lý phù hợp trước khi tiếp tục thu thập dữ liệu.

d. Quy trình thu thập dữ liệu

Quá trình thu thập dữ liệu được thực hiện theo quy trình gồm bốn bước chính nhằm đảm bảo dữ liệu được thu thập đầy đủ, có cấu trúc và phản ánh đa dạng các loại hình bất động sản trên địa bàn tỉnh Bình Định.

Đầu tiên, hệ thống truy cập vào các chuyên mục bất động sản trên hai website Alonhadat và Batdongsan. Để đảm bảo tính đa dạng của dữ liệu, chương trình tự động duyệt qua nhiều loại hình bất động sản khác nhau như căn hộ chung cư, nhà mặt tiền, nhà trong hẻm, biệt thự, đất ở và đất dự án.

Trong chương trình, các chuyên mục được định nghĩa dưới dạng tập hợp dữ liệu như sau:

```

CATEGORIES = {
    "Căn hộ chung cư",
    "Nhà mặt tiền",
    "Nhà trong hẻm",
    "Biệt thự, nhà liền kề",
    "Đất thổ cư/đất ở",
    "Đất nền/liền kề/đất dự án"
}

```

Việc phân loại ngay từ giai đoạn thu thập giúp dữ liệu sau này có thể được phân tích theo từng phân khúc thị trường riêng biệt

Sau khi truy cập vào từng chuyên mục, hệ thống sử dụng Selenium kết hợp với Undetected ChromeDriver để mô phỏng trình duyệt thực và tải đầy đủ nội dung trang web. Đây là giải pháp phù hợp đối với các website sử dụng JavaScript động hoặc cơ chế chống bot.

Sau khi trang web được tải hoàn chỉnh, BeautifulSoup được sử dụng để phân tích cấu trúc HTML và hỗ trợ tìm kiếm các thành phần chứa thông tin bất động sản.

```
soup = BeautifulSoup(driver.page_source, 'html.parser')
```

Thông qua đối tượng soup, chương trình có thể xác định các khối chứa tin đăng, đường dẫn chi tiết, tiêu đề, giá bán và các thuộc tính khác của bất động sản.

Sau khi xác định được danh sách tin đăng trên mỗi trang, chương trình lần lượt truy cập vào từng bài đăng để thu thập thông tin chi tiết của bất động sản. Các thông tin được lưu dưới dạng từ điển (Dictionary) trước khi đưa vào danh sách dữ liệu tổng hợp.

```
item_info = {
    "loai_bds": category_name,
    "tieu_de": title,
    "gia": price_text,
    "dien_tich": area_text,
    "kich_thuoc": kt_clean,
    "huong": direction_clean,
    "so_tang": floors,
    "so_phong_ngu": rooms,
    "so_phong_vs": wcs,
    "phap_ly": legal_clean,
    "quan_huyen": quan_huyen_clean,
    "dia_chi": address_detail,
    "nguồn": url_detail
}
```

Việc lưu dữ liệu dưới dạng cấu trúc có tổ chức giúp quá trình xử lý và làm sạch dữ liệu ở các bước tiếp theo trở nên thuận lợi hơn.

Trong quá trình thu thập, chương trình đồng thời thực hiện kiểm tra các cơ chế bảo vệ của website như Cloudflare nhằm đảm bảo quá trình crawling diễn ra ổn định và hạn chế nguy cơ bị chặn truy cập.

Sau khi hoàn tất việc thu thập, toàn bộ dữ liệu được tổng hợp thành một bảng dữ liệu (DataFrame) bằng thư viện Pandas và xuất ra tệp CSV để phục vụ cho giai đoạn tiền xử lý và phân tích dữ liệu.

```
df = pd.DataFrame(all_data)
file_name = "raw_batdongsan_data.csv"
```

Thông qua quy trình trên, dữ liệu được thu thập hoàn toàn tự động, giảm đáng kể thời gian nhập liệu thủ công, đồng thời đảm bảo tính nhất quán giữa các bản ghi. Kết quả thu được là một bộ dữ liệu có cấu trúc bao gồm các thông tin về giá bán, diện tích, vị trí địa lý, đặc điểm công năng, tình trạng pháp lý và loại hình bất động sản.

3. Tiền xử lý dữ liệu

Sau khi hoàn thành quá trình thu thập dữ liệu từ các website bất động sản, bộ dữ liệu ban đầu vẫn tồn tại nhiều vấn đề thường gặp trong dữ liệu thực tế như dữ liệu trùng lặp, định dạng không đồng nhất, dữ liệu thiếu, thông tin mô tả không có cấu trúc và sự khác biệt trong cách biểu diễn cùng một thuộc tính giữa các tin đăng. Nếu không được

xử lý, các vấn đề này có thể làm sai lệch kết quả phân tích thống kê cũng như ảnh hưởng đến độ chính xác của các mô hình dự đoán giá bất động sản.

Do đó, bước tiền xử lý dữ liệu được thực hiện nhằm chuẩn hóa dữ liệu đầu vào, loại bỏ các thành phần nhiễu và xây dựng tập dữ liệu có cấu trúc phù hợp cho quá trình phân tích dữ liệu khám phá (Exploratory Data Analysis - EDA) và xây dựng mô hình học máy ở các chương tiếp theo.

a. Khởi tạo và hợp nhất dữ liệu đa nguồn

Việc hợp nhất dữ liệu đa nền tảng không chỉ đơn thuần là gộp tệp tin mà là bước đồng bộ hóa schema (cấu trúc bảng) để đảm bảo tính nhất quán cho toàn bộ pipeline xử lý phía sau.

Quy trình kỹ thuật:

- Đồng bộ hóa Schema: Sử dụng thư viện Pandas để thực hiện ánh xạ cột. Cụ thể, hệ thống tiến hành đổi tên cột `so_phong_vs` của tập dữ liệu từ Batdongsan (`df2`) thành `so_wc` để tương thích hoàn toàn với cấu trúc của Alonhadat (`df1`).
- Hợp nhất chiến lược: Áp dụng hàm `pd.concat` với tham số `ignore_index=True`. Thao tác này giúp reset toàn bộ chỉ số dòng từ 0, tạo ra tệp `raw_data.csv` đồng nhất, loại bỏ lỗi chỉ mục khi truy vấn tập hợp lớn.

```
df1 = pd.read_csv("raw_alonhadat_data.csv")
df2 = pd.read_csv("raw_batdongsan_data.csv")
df_merged1 = pd.concat([df1, df2], axis=0, ignore_index=True)
df_merged1.to_csv('raw_data.csv', index=False, encoding='utf-8-sig')
```

Việc hợp nhất dữ liệu giúp tăng kích thước mẫu nghiên cứu, đồng thời làm phong phú thêm các loại hình bất động sản xuất hiện trong tập dữ liệu. Sau bước này, toàn bộ thông tin từ nhiều nguồn khác nhau được đưa về cùng một cấu trúc dữ liệu thống nhất để tiếp tục xử lý.

Ngoài việc mở rộng quy mô mẫu, việc kết hợp nhiều nguồn dữ liệu còn giúp giảm hiện tượng thiên lệch thông tin (Data Bias). Một số loại hình bất động sản xuất hiện nhiều trên Alonhadat nhưng ít xuất hiện trên Batdongsan và ngược lại. Do đó việc tổng hợp dữ liệu từ nhiều nguồn giúp phản ánh đầy đủ hơn bức tranh chung của thị trường bất động sản Bình Định.

b. Kiểm tra và loại bỏ dữ liệu trùng lặp

Trong quá trình đăng tin, một bất động sản có thể được đăng nhiều lần hoặc xuất hiện đồng thời trên nhiều website khác nhau. Điều này dẫn đến hiện tượng các bản ghi bị lặp lại.

Việc giữ nguyên các bản ghi trùng lặp có thể làm sai lệch kết quả phân tích thống kê cũng như ảnh hưởng đến khả năng học của mô hình dự đoán.

Do đó, dữ liệu được kiểm tra dựa trên các thuộc tính quan trọng như:

- Địa chỉ
- Tiêu đề tin đăng
- Diện tích
- Giá bán

Các dòng dữ liệu trùng lặp hoàn toàn được loại bỏ, chỉ giữ lại một bản ghi đại diện.

Việc loại bỏ dữ liệu trùng lặp giúp giảm nhiễu và phản ánh chính xác hơn tình hình thực tế của thị trường bất động sản.

Quy trình kỹ thuật:

- Xử lý trùng lặp hoàn toàn: Sử dụng `drop_duplicates(keep='first')` để loại bỏ các bản ghi trùng khớp 100% trên tất cả các trường thông tin.
- Kiểm soát trùng lặp thực tế (Physical Deduplication): Hệ thống sử dụng tham số subset để tập trung kiểm tra nhóm cột cốt lõi gồm: gia, dien_tich, so_tang, quan_huyen, và dia_chi. Trước khi loại bỏ, dữ liệu được sắp xếp (`sort_values`) theo mức độ đầy đủ của thông tin để đảm bảo `keep='first'` luôn giữ lại bản ghi có giá trị tham chiếu cao nhất.

c. Tách kích thước mặt tiền và chiều sâu

Thông tin kích thước lô đất hoặc căn nhà thường được lưu dưới dạng chuỗi ký tự, ví dụ:

- 5m x 20m
- 4.5 x 18
- 10 x 30

Dạng dữ liệu này không phù hợp cho các thuật toán học máy vì chứa đồng thời hai giá trị trong cùng một cột.

Do đó, tiến hành phân tách thông tin kích thước thành hai thuộc tính riêng biệt:

- **ngang (m):** chiều rộng mặt tiền
- **doc (m):** chiều dài thửa đất

Quy trình kỹ thuật:

- Làm sạch chuỗi (String Sanitization): Chuyển đổi toàn bộ về chữ thường, thay dấu phẩy thập phân kiểu Việt Nam thành dấu chấm hệ thống, và loại bỏ các đơn vị văn bản "m", "m²".
- Trích xuất bằng biểu thức chính quy (Regex): Sử dụng Pattern `r'(\d+\.\d*)\s*x\s*(\d+\.\d*)'` để tách cột `kich_thuoc` thành hai trường số liệu riêng biệt: `ngang (m)` và `doc (m)`.
- Vector hóa số liệu: Ép kiểu dữ liệu về dạng float bằng `pd.to_numeric` với tham số `errors='coerce'`. Đây là chi tiết kỹ thuật then chốt giúp chuyển đổi các chuỗi văn bản không hợp lệ thành NaN, đảm bảo hệ thống không bị crash và sẵn sàng cho các phép toán ma trận. Cuối cùng, dữ liệu được làm tròn bằng hàm `.round(1)`.

```
temp = (
    df3['kich_thuoc']
    .astype(str)
    .str.lower()
    .str.replace(',', '.', regex=False)
    .str.replace('m', '', regex=False)
)
df3[['ngang (m)', 'doc (m)']] = temp.str.extract(
    r'(\d+\.\d*)\s*x\s*(\d+\.\d*)'
```

```
)
df3['ngang (m)'] = pd.to_numeric(df3['ngang (m)'], errors='coerce')
df3['doc (m)'] = pd.to_numeric(df3['doc (m)'], errors='coerce')
df3.drop(columns=['kich_thuoc'], inplace=True)
df3[['ngang (m)', 'doc (m)']].head(10)
```

Việc tách riêng hai chiều giúp:

- Tính toán diện tích dễ dàng hơn.
- Phân tích ảnh hưởng của mặt tiền đến giá bất động sản.
- Tăng khả năng học của mô hình dự đoán.

d. Làm sạch dữ liệu trong các cột số

Trong quá trình thu thập dữ liệu từ các website bất động sản, dữ liệu đầu vào thường không ở dạng số thuần túy mà tồn tại dưới dạng chuỗi ký tự kết hợp giữa số, chữ và đơn vị đo lường. Điều này xuất phát từ cách hiển thị dữ liệu của website nhằm phục vụ người dùng, nhưng lại gây ra rất nhiều khó khăn khi đưa vào phân tích dữ liệu và huấn luyện mô hình học máy.

Các cột mang tính định lượng trong bộ dữ liệu như **giá bán, diện tích, số tầng, số phòng ngủ, số WC, chiều ngang, chiều dọc** đều bị ảnh hưởng bởi tình trạng này. Nếu không được chuẩn hóa, các thuật toán thống kê và mô hình dự đoán sẽ không thể hoạt động chính xác do dữ liệu không còn mang ý nghĩa toán học thuần túy.

Do đó, bước làm sạch dữ liệu số được xem là một trong những bước quan trọng nhất trong toàn bộ quy trình tiền xử lý.

Quy trình kỹ thuật:

- Thuật toán quy đổi giá: Xây dựng hàm chuyển đổi toàn bộ về đơn vị chuẩn "Tỷ". Nếu tin đăng chứa từ khóa "triệu", hệ thống thực hiện phép chia cho 1000. Các giá trị "Giá thỏa thuận" được chuyển về NaN để đảm bảo tính chính xác của các phép tính trung bình và độ lệch chuẩn.
- Hàm bóc tách đa năng process_column: Sử dụng Regex `r'([-+]?\d*\.\d+)` để trích xuất cụm số đầu tiên từ các chuỗi phức tạp như "3 tầng + 1 tum" hay "4 PN".
- Làm sạch văn bản chuyên sâu: Loại bỏ triệt để Emoji và ký tự đặc biệt bằng cách quét qua các khối mã Unicode (như \U0001F600-\U0001F64F cho Emoticons).

e. Chuẩn hóa Biến phân loại và Trích xuất Thực thể Địa danh

Thách thức lớn nhất của dữ liệu bất động sản là địa chỉ không cấu trúc. Hệ thống cần chuyển đổi chúng thành các thực thể địa lý có thể phân nhóm.

Quy trình kỹ thuật:

- Mapping từ điển: Sử dụng bảng Mapping để đồng bộ hóa địa danh (ví dụ: "h. phù cát" thành "Huyện Phù Cát", "tx. hoài nhơn" thành "Thị xã Hoài Nhơn").
- Chiến lược trích xuất Hybrid (7 cấp độ):
 - Regex-based: Tìm kiếm văn bản sau từ khóa "đường".

- Dictionary-based: Sử dụng thư viện FlashText đối soát siêu tốc với danh mục hơn 500 tuyến đường tại Bình Định (QL19, Nguyễn Tất Thành, Xuân Diệu...).
- Garbage Smashing: Áp dụng thuật toán loại bỏ từ nhiều bám đuôi như "ôtô", "view biển", "chính chủ" thông qua cơ chế re.sub và danh sách blacklist

f. Phân nhóm Chiến lược và "Agentic Imputation" cho Dữ liệu Khuyết thiếu

Triết lý xử lý dữ liệu thiếu trong hệ thống này không chỉ là lấp đầy khoảng trống, mà là "điền khuyết có ngữ cảnh" để duy trì tính trung thực của dữ liệu.

Quy trình kỹ thuật:

- Phân nhóm Macro (nhom_bds_lon): Chia toàn bộ dữ liệu thành hai nhóm lớn: "Đất" và "Nhà".
- Chiến thuật điền khuyết theo ngữ cảnh:
 - Nhóm Đất: Các cột so_tang, so_phong_ngu, so_wc được mặc định về 0.
 - Nhóm Nhà: Điền giá trị khuyết bằng Mode (giá trị phổ biến nhất) của từng phân khúc nhỏ (ví dụ: Nhà riêng/Trong hẻm). Nếu phân khúc nhỏ trống, hệ thống sẽ sử dụng Global Mode của nhóm Nhà.
- Hệ thống Flagging: Mỗi giá trị được điền khuyết sẽ đi kèm một cột boolean (ví dụ: so_tang_is_predicted = 1).

g. Kiểm soát và Xử lý Giá trị Ngoại lai (Outlier Handling)

Để bảo vệ các mô hình dự báo khỏi sự nhiễu loạn của giá ảo hoặc lỗi nhập liệu, chúng ta cần một quy trình lọc ngoại lai đa tầng.

Quy trình kỹ thuật:

- Physical Sanity Check (Kiểm tra tính hợp lý vật lý): Loại bỏ ngay lập tức các dòng có thông số vô lý như chiều sâu doc (m) > 100 hoặc đơn giá triệu/m² > 290.
- Statistical Trimming (Cắt tỉa thống kê): Sử dụng phân vị Quantile 0.98 cho gia(ty) và dien_tich(m²). Phương pháp này ưu việt hơn IQR truyền thống vì nó chỉ loại bỏ 2% các giá trị cực đoan nhất ở đỉnh, giúp giữ lại được các bất động sản thuộc phân khúc cao cấp thực sự.
- Market Floor Filtering: Áp dụng mức giá sàn muc_gia_san (ví dụ: 10 triệu/m²) để lọc bỏ các tin đăng có giá trị thấp bất thường không phù hợp với thực tế thị trường Bình Định.

4. Kết quả dữ liệu sau khi xử lý

Sau toàn bộ quá trình làm sạch, chuẩn hóa và xử lý dữ liệu, bộ dữ liệu nghiên cứu cuối cùng thu được gồm 767 quan sát bất động sản trên địa bàn tỉnh Bình Định. Mỗi quan sát được biểu diễn thông qua các thuộc tính quan trọng phản ánh đầy đủ đặc điểm của bất động sản, bao gồm:

- Giá bán.
- Đơn giá bất động sản.
- Diện tích.
- Kích thước mặt tiền và chiều sâu.

- Loại hình bất động sản.
- Địa chỉ và quận/huyện.
- Hướng nhà.
- Tình trạng pháp lý.
- Số tầng.
- Số phòng ngủ.
- Số phòng vệ sinh.

Trong quá trình tiền xử lý, dữ liệu đã được kiểm tra và loại bỏ các bản ghi trùng lặp, chuẩn hóa đơn vị đo lường, đồng nhất cách biểu diễn của các biến phân loại, xử lý dữ liệu khuyết thiếu theo từng nhóm bất động sản, đồng thời kiểm soát các giá trị ngoại lai nhằm đảm bảo tính hợp lý của dữ liệu. Bên cạnh đó, các thuộc tính quan trọng như tên đường, nhóm loại bất động sản và đơn giá trên mét vuông cũng được xây dựng và bổ sung nhằm gia tăng khả năng khai thác thông tin của bộ dữ liệu.

Kết quả thu được là một tập dữ liệu có mức độ nhất quán cao, giảm đáng kể hiện tượng dữ liệu nhiễu, dữ liệu sai định dạng, dữ liệu thiếu và các giá trị bất thường. Các biến số đều đã được chuyển đổi về dạng dữ liệu phù hợp cho quá trình phân tích định lượng và xây dựng mô hình học máy.

Sau khi hoàn tất toàn bộ các bước tiền xử lý, bộ dữ liệu đã được lưu trữ dưới dạng tệp **clean_data.csv**. Đây được xem là tập dữ liệu chuẩn hóa cuối cùng của đề tài, đóng vai trò là nguồn dữ liệu đầu vào chính cho các bước phân tích ở các chương tiếp theo. Việc lưu trữ thành tệp riêng không chỉ giúp bảo toàn kết quả tiền xử lý mà còn tạo điều kiện thuận lợi cho quá trình tái sử dụng dữ liệu, huấn luyện mô hình, đánh giá kết quả và triển khai các thử nghiệm khác nhau mà không cần thực hiện lại toàn bộ quy trình làm sạch dữ liệu từ đầu.

CHƯƠNG IV. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU VÀ ĐẶC TRƯNG THỊ TRƯỜNG BẤT ĐỘNG SẢN BÌNH ĐỊNH

1. Phân tích thống kê phân phối giá và cấu trúc thị trường bất động sản bình định


Khi đưa các biến số tài chính bất động sản tại Bình Định vào hệ hình thống kê, hai biến mục tiêu cốt lõi quy định cấu trúc phân bổ dòng vốn là Tổng giá ròng (gia(ty)) và Đơn giá (trieu/m2) bộc lộ các trạng thái phân phối phi tuyến, phân hóa sâu sắc dựa trên việc chia tách hai danh mục lớn: **Nhà (337 quan sát)** và **Đất (430 quan sát)**.

Chỉ số thống kê	Danh mục Nhà (337 mẫu)	Danh mục Đất (430 mẫu)	Tỷ lệ chênh lệch
Giá trị tổng ròng trung bình	4.95 Tỷ VNĐ	2.92 Tỷ VNĐ	Nhà cao gấp 1.69 lần
Đơn giá mét vuông trung bình	59.06 Triệu/m ²	24.79 Triệu/m ²	Nhà cao gấp 2.38 lần
Diện tích mặt bằng trung bình	83.17 m ²	120.42 m ²	Đất rộng gấp 1.45 lần

a. Phân tích thống kê mô tả các chỉ tiêu giá và diện tích theo phân khúc bất động sản

- Kết quả tính toán trực tiếp từ dữ liệu thực địa cho thấy một khoảng cách tài chính đáng kinh ngạc giữa bản chất của tài sản xây sẵn và tư liệu đất thô:
 - **Danh mục Nhà:** Ghi nhận giá trị tổng ròng trung bình đạt **4.95 tỷ VNĐ/tài sản**, đơn giá trung bình chạm ngưỡng **59.06 triệu VNĐ/m²**, định vị trên quy mô diện tích sàn đất trung bình đạt **83.17 m²**.
 - **Danh mục Đất:** Sở hữu tổng giá trị trung bình thấp hơn đáng kể, đạt **2.92 tỷ VNĐ/thửa đất**, đơn giá trung bình giữ mức **24.79 triệu VNĐ/m²**, nhưng lại áp đảo về không gian mặt bằng với diện tích trung bình lên tới **120.42 m²**.

Giá trung bình và Độ biến động giữa Nhà và Đất




- Sự chênh lệch đơn giá bình quân gấp **2.38 lần** giữa hai danh mục khẳng định thị trường Bình Định đang chi trả một phần bù rất lớn cho giá trị xây thô hoàn thiện, kết hợp cùng thặng dư khai thác thương mại trực tiếp dòng tiền của các công trình kiến trúc xây sẵn so với đất nền thô chưa đầu tư kỹ thuật.

b. Phân tích phân phối giá căn hộ chung cư tại Quy Nhơn

- Đối với phân khúc căn hộ chung cư (217 quan sát), kết quả phân tích phân phối đơn giá (triệu đồng/m²) thông qua biểu đồ mật độ xác suất (Probability Density Function - PDF) cho thấy dữ liệu không tuân theo phân phối đơn đỉnh mà xuất hiện nhiều đỉnh cục bộ (multimodal distribution). Điều này phản ánh sự tồn tại của các nhóm sản phẩm có mức giá khác nhau trên thị trường căn hộ Quy Nhơn.
- Phân phối giá có thể được chia thành ba nhóm chính:
 - **Nhóm căn hộ giá thấp (20–30 triệu đồng/m²):** Chủ yếu tập trung tại các khu vực ven trung tâm hoặc các dự án phục vụ nhu cầu ở thực. Một số dự án tiêu biểu ghi nhận mức giá dao động quanh 20–25 triệu đồng/m². Nhóm này có biên độ giá tương đối hẹp, cho thấy mức độ biến động thấp hơn so với các nhóm còn lại.
 - **Nhóm căn hộ trung cấp (30–55 triệu đồng/m²):** Đây là nhóm chiếm tỷ trọng lớn nhất trong tập dữ liệu. Các dự án thuộc nhóm này thường nằm trong khu vực nội đô hoặc các khu dân cư phát triển đồng bộ. Mức giá phổ biến dao động từ 35–40 triệu đồng/m², phản ánh phân khúc có nhu cầu giao dịch và khả năng tiếp cận cao đối với phần lớn người mua nhà.
 - **Nhóm căn hộ cao cấp (50–90 triệu đồng/m²):** Tập trung ở các dự án sở hữu vị trí đặc địa, đặc biệt là khu vực ven biển hoặc trung tâm thành phố. Sự xuất hiện của nhóm này tạo nên phần đuôi phải của phân phối giá, kéo giá trị trung bình toàn bộ phân khúc lên cao hơn đáng kể so với giá trị trung vị.

c. Phân bố giá bất động sản theo vị trí tuyến đường tại thành phố Quy Nhơn




- Kết quả thống kê giá trị bất động sản theo tên đường cho thấy vị trí địa lý có ảnh hưởng đáng kể đến mặt bằng giá. Biểu đồ giá trung bình của 20 tuyến đường có số lượng giao dịch lớn nhất cho thấy sự phân hóa rõ rệt giữa các khu vực trung tâm, ven biển và các khu vực mở rộng đô thị.
 - **Nhóm giá cao (trên 6 tỷ đồng/tài sản):** Nhóm này bao gồm các tuyến đường có vị trí trung tâm hoặc sở hữu lợi thế về thương mại, dịch vụ và du lịch. Đứng đầu là đường **An Dương Vương** với giá trung bình vượt 10 tỷ đồng, cao hơn đáng kể so với các tuyến đường còn lại. Tiếp theo là các tuyến **Hai Bà Trưng, Nguyễn Nhạc, Lê Hồng Phong, Trần Phú, Chương Dương và Ngô Mây**, với mức giá trung bình dao động từ khoảng 6 đến 8 tỷ đồng. Đây là những khu vực tập trung nhiều hoạt động kinh doanh, có khả năng tiếp cận hạ tầng và tiện ích đô thị thuận lợi.
 - **Nhóm giá trung bình (từ 3 đến dưới 6 tỷ đồng/tài sản):** Các tuyến đường thuộc nhóm này bao gồm **Hoàng Sa, Nguyễn Tất Thành, Điện Biên Phủ, Trần Hưng Đạo, Tây Sơn và Nguyễn Thái Học**. Mức giá trung bình dao động từ khoảng 3,5 đến 6 tỷ đồng. Đây là các khu vực có mật độ dân cư tương đối cao, kết nối thuận lợi với trung tâm thành phố và đáp ứng tốt nhu cầu ở thực cũng như đầu tư dài hạn.
 - **Nhóm giá thấp hơn (dưới 3 tỷ đồng/tài sản):** Nhóm này gồm các tuyến **Hoàng Văn Thụ, Lê Duẩn, Nguyễn Huệ, Nguyễn Diêu, Lê Đức Thọ và Võ Nguyên Giáp**. Giá trung bình dao động từ khoảng 1,8 đến 3 tỷ đồng. So với các khu vực trung tâm, mặt bằng giá tại các tuyến đường này thấp hơn, tạo điều kiện tiếp cận cho nhiều đối tượng khách hàng hơn. Đồng thời, một

số khu vực nằm trong nhóm này vẫn có tiềm năng tăng trưởng khi quá trình mở rộng đô thị và đầu tư hạ tầng tiếp tục diễn ra.

- Nhìn chung, kết quả phân tích cho thấy **vị trí tuyến đường là một trong những yếu tố có tác động mạnh đến giá bất động sản**. Các tuyến đường ven biển và khu vực trung tâm thành phố thường có mức giá cao hơn đáng kể so với các khu vực nằm xa trung tâm hoặc đang trong quá trình phát triển. Điều này cho thấy biến "tên đường" hoặc "vị trí" cần được xem xét như một biến quan trọng trong quá trình xây dựng mô hình dự đoán giá bất động sản.

2. Phân tích ma trận tương quan và mối quan hệ giữa các biến đặc trưng



a. Mối quan hệ giữa kích thước mặt tiền và chiều sâu thửa đất

- Kết quả phân tích cho thấy chiều ngang và chiều sâu thửa đất có tương quan dương mạnh với hệ số Pearson đạt 0.78. Điều này cho thấy các thửa đất có mặt tiền lớn thường đi kèm với chiều sâu lớn hơn.
- Hệ số xác định $R^2 = 0.78^2 \approx 0.61$ cho thấy khoảng 61% biến thiên của chiều sâu có thể được giải thích bởi biến chiều ngang trong mô hình tuyến tính đơn giản. Kết quả này phản ánh xu hướng phân lô tương đối đồng bộ trong tập dữ liệu khảo sát. Các thửa đất có diện tích lớn thường được mở rộng đồng thời theo cả chiều ngang và chiều sâu thay vì chỉ phát triển theo một chiều. Đây là

đặc điểm thường gặp tại các khu dân cư được quy hoạch đồng bộ và các khu đô thị mới.


b. *Mối quan hệ giữa quy mô thửa đất và số tầng xây dựng*

- Ma trận tương quan cho thấy số tầng có mối tương quan âm với chiều ngang ($r = -0.56$), chiều sâu ($r = -0.65$) và diện tích đất ($r = -0.31$).
- Các kết quả này cho thấy những bất động sản có diện tích đất nhỏ hơn có xu hướng được xây dựng nhiều tầng hơn, trong khi các bất động sản sở hữu diện tích lớn thường có số tầng thấp hơn.
- Xu hướng này có thể được lý giải bởi nhu cầu tối ưu hóa diện tích sử dụng trên các lô đất hạn chế về mặt bằng, đặc biệt tại khu vực đô thị. Ngược lại, các lô đất có diện tích lớn thường có điều kiện bố trí không gian theo phương ngang, giảm nhu cầu phát triển chiều cao công trình.
- Mặc dù vậy, cần lưu ý rằng tương quan không đồng nghĩa với quan hệ nhân quả. Số tầng còn chịu ảnh hưởng của nhiều yếu tố khác như quy hoạch xây dựng, mục đích sử dụng, loại hình bất động sản và điều kiện kinh tế của chủ sở hữu.

c. *Mối liên hệ giữa số phòng ngủ và số nhà vệ sinh*

- Kết quả phân tích cho thấy số phòng ngủ và số nhà vệ sinh có tương quan dương khá mạnh với hệ số Pearson đạt 0.68.
- Điều này phản ánh xu hướng các công trình có nhiều phòng ngủ thường được thiết kế với nhiều nhà vệ sinh hơn nhằm đáp ứng nhu cầu sử dụng của số lượng cư dân lớn hơn. Mối quan hệ này phù hợp với nguyên tắc thiết kế nhà ở hiện đại, trong đó quy mô không gian sinh hoạt và các tiện ích phụ trợ thường được phát triển đồng thời.
- Bên cạnh đó, số phòng ngủ và số nhà vệ sinh đều có tương quan dương mức trung bình với giá bất động sản (lần lượt 0.41 và 0.43), cho thấy các đặc điểm công năng của ngôi nhà có thể đóng vai trò quan trọng trong việc hình thành giá trị tài sản.

3. Phân tích phân bố giá bất động sản theo không gian địa lý



Biểu đồ giá trị bất động sản trung bình theo quận, huyện cho thấy thị trường bất động sản Bình Định tồn tại sự phân hóa không gian tương đối rõ nét giữa các địa phương. Giá trị trung bình của bất động sản dao động từ 1,54 tỷ đồng đến 5,20 tỷ đồng, tạo nên khoảng cách lên tới 3,66 tỷ đồng giữa khu vực có mức giá cao nhất và thấp nhất trong tập dữ liệu. Điều này phản ánh sự khác biệt đáng kể về sức hấp dẫn của từng địa bàn trong quá trình hình thành giá trị bất động sản.

a. Nhóm địa phương có mặt bằng giá cao

- Nhóm dẫn đầu bao gồm Huyện Phù Mỹ, Huyện Phù Cát và Thành phố Quy Nhơn với mức giá trung bình đều vượt ngưỡng 4,5 tỷ đồng mỗi bất động sản.
 - Huyện Phù Mỹ ghi nhận mức giá trung bình cao nhất, đạt khoảng 5,20 tỷ đồng.
 - Huyện Phù Cát đứng thứ hai với khoảng 4,76 tỷ đồng.
 - Thành phố Quy Nhơn đứng thứ ba với khoảng 4,67 tỷ đồng.
- Khoảng cách giữa Phù Cát và Quy Nhơn chỉ khoảng 90 triệu đồng, tương đương chưa tới 2%, cho thấy mặt bằng giá trung bình giữa hai địa phương này tương đối tương đồng.
- Đáng chú ý, mức giá trung bình của Phù Mỹ cao hơn Quy Nhơn khoảng 530 triệu đồng, tương ứng gần 11,4%. Điều này cho thấy trong tập dữ liệu khảo sát đã xuất hiện những bất động sản có giá trị lớn tại khu vực này, góp phần nâng mặt bằng giá trung bình lên mức cao nhất toàn biểu đồ.
- Sự hiện diện của ba địa phương có giá trị trung bình vượt xa phần còn lại cho thấy đây là nhóm tạo nên tầng giá cao của thị trường bất động sản Bình Định.

b. Thành phố Quy Nhơn – Trung tâm giá trị của thị trường bất động sản tỉnh

- Mặc dù không đứng đầu về giá trị trung bình, Thành phố Quy Nhơn vẫn duy trì vị thế là một trong những khu vực có mặt bằng giá cao nhất trong nghiên cứu với mức giá trung bình đạt khoảng 4,67 tỷ đồng mỗi bất động sản.
- Khoảng cách giữa Quy Nhơn và nhóm địa phương phía sau là khá lớn. Cụ thể:
 - Cao hơn An Nhơn khoảng 2,15 tỷ đồng.
 - Cao hơn Vân Canh khoảng 2,33 tỷ đồng.
 - Cao hơn Tuy Phước khoảng 2,84 tỷ đồng.
 - Cao hơn Hoài Nhơn khoảng 3,13 tỷ đồng.
- Nếu xét theo tỷ lệ, giá trị bất động sản trung bình tại Quy Nhơn cao gấp khoảng 3 lần so với Hoài Nhơn và hơn 2,5 lần so với Tuy Phước.
- Những con số này cho thấy Quy Nhơn vẫn là địa bàn sở hữu mặt bằng giá cao và có khả năng tạo ra giá trị tài sản vượt trội so với phần lớn các địa phương còn lại trong tỉnh.

c. Nhóm địa phương có mặt bằng giá trung bình

- Thị xã An Nhơn và Huyện Vân Canh tạo thành nhóm giá trung bình với mức giá dao động từ 2,3 đến 2,5 tỷ đồng mỗi bất động sản.
 - Thị xã An Nhơn đạt khoảng 2,52 tỷ đồng.
 - Huyện Vân Canh đạt khoảng 2,34 tỷ đồng.

- Khoảng cách giữa hai địa phương chỉ khoảng 180 triệu đồng, tương đương gần 7,7%, cho thấy sự tương đồng tương đối về mặt bằng giá trong tập dữ liệu khảo sát.
- Tuy nhiên, khi so sánh với nhóm dẫn đầu, mức giá tại An Nhơn chỉ bằng khoảng 53% so với Phù Cát và khoảng 48% so với Phù Mỹ. Điều này phản ánh sự tồn tại của một khoảng cách đáng kể giữa tầng giá trung bình và tầng giá cao trên thị trường.

d. Nhóm địa phương có mặt bằng giá thấp

- Ở nhóm cuối bảng xếp hạng, Huyện Tuy Phước và Thị xã Hoài Nhơn ghi nhận mức giá trung bình thấp nhất.
 - Huyện Tuy Phước đạt khoảng 1,83 tỷ đồng.
 - Thị xã Hoài Nhơn đạt khoảng 1,54 tỷ đồng.
- Khoảng cách giữa hai địa phương là khoảng 290 triệu đồng. Trong khi đó, nếu so với địa phương dẫn đầu là Phù Mỹ, mức giá trung bình tại Hoài Nhơn thấp hơn tới 3,66 tỷ đồng.
- Xét theo tỷ lệ tương đối, giá trị bất động sản trung bình tại Hoài Nhơn chỉ tương đương khoảng 29,6% so với Phù Mỹ, khoảng 32,4% so với Phù Cát và khoảng 33,0% so với Thành phố Quy Nhơn.
- Điều này cho thấy sự khác biệt rất lớn về mặt bằng giá giữa các khu vực trong tỉnh, đồng thời phản ánh tính không đồng nhất của thị trường bất động sản Bình Định.

e. Nhận xét tổng quát


- Từ biểu đồ có thể nhận thấy thị trường bất động sản Bình Định được phân thành ba tầng giá tương đối rõ ràng:
 - Tầng giá cao gồm Phù Mỹ, Phù Cát và Quy Nhơn với giá trị trung bình trên 4,5 tỷ đồng.
 - Tầng giá trung bình gồm An Nhơn và Vân Canh với giá trị dao động quanh mức 2,3–2,5 tỷ đồng.
 - Tầng giá thấp gồm Tuy Phước và Hoài Nhơn với giá trị dưới 2 tỷ đồng.
- Kết quả này cho thấy thị trường bất động sản Bình Định không có sự phân bố đồng đều về giá trị tài sản giữa các địa phương. Các khu vực như Phù Mỹ, Phù Cát và Quy Nhơn đang hình thành nhóm có giá trị bất động sản cao, trong khi Tuy Phước và Hoài Nhơn thuộc nhóm có mặt bằng giá thấp hơn đáng kể. Sự khác biệt này cho thấy yếu tố vị trí địa lý và đặc điểm phát triển của từng địa phương.

4. Phân tích mật độ tin đăng, tác động của pháp lý và hướng bất động sản đến giá trị tài sản

Thông tin mô tả trong tin đăng bất động sản là một trong những nguồn dữ liệu quan trọng phản ánh đặc điểm của thị trường. Bên cạnh các yếu tố truyền thống như vị trí, diện tích hay loại hình tài sản, các biến liên quan đến tuyến đường, tình trạng pháp lý và hướng nhà cũng có thể ảnh hưởng đến giá trị bất động sản. Trong phần này, dữ liệu

được phân tích thông qua ba nhóm yếu tố gồm: mật độ xuất hiện của tin đăng theo tuyến đường, tình trạng pháp lý và hướng bất động sản.

a. Phân tích Mật độ Tin đăng theo Tuyến đường



i) Nhóm tin đăng không xác định vị trí

- Trong tổng số 767 quan sát, có tới **420 tin đăng không ghi rõ tên đường**, chiếm khoảng **54,76%** toàn bộ dữ liệu.
- Tỷ lệ này phản ánh một thực trạng phổ biến của thị trường bất động sản trực tuyến, khi nhiều tin đăng chỉ cung cấp thông tin khu vực hoặc phường/xã mà không công bố địa chỉ cụ thể. Nguyên nhân có thể xuất phát từ:
 - Bảo mật thông tin khách hàng.
 - Tránh cạnh tranh trực tiếp giữa các đơn vị môi giới.
 - Tin đăng được tổng hợp từ nhiều nguồn khác nhau.
 - Các dự án chưa xác định chính xác vị trí lô đất hoặc căn nhà.
- Việc thiếu thông tin vị trí cụ thể tạo ra một mức độ bất đối xứng thông tin nhất định, đồng thời làm giảm khả năng khai thác các biên địa lý trong quá trình xây dựng mô hình dự báo giá.

ii) Các tuyến đường có mật độ giao dịch cao

Loại bỏ nhóm "Không rõ", các tuyến đường xuất hiện nhiều nhất bao gồm:


Tuyến đường	Số tin đăng
Nguyễn Thái Học	22
Hoàng Văn Thụ	19
Điện Biên Phủ	18
Trần Hưng Đạo	16
Tây Sơn	13

Lê Đức Thọ	10
Nguyễn Huệ	8
Ngô Máy	7
Trần Phú	7
Nguyễn Diêu	7

- Các tuyến đường trên đều thuộc khu vực nội thành Quy Nhơn hoặc các vùng đô thị phát triển mạnh. Số lượng tin đăng lớn phản ánh nhu cầu mua bán, chuyển nhượng và đầu tư tương đối sôi động tại các khu vực này.
- Đặc biệt:
 - Nguyễn Thái Học dẫn đầu với 22 tin đăng.
 - Hoàng Văn Thụ và Điện Biên Phủ lần lượt đạt 19 và 18 tin đăng.
 - Trần Hưng Đạo ghi nhận 16 tin đăng, cho thấy đây vẫn là một trong những trục giao thông có sức hút lớn đối với thị trường.
- Mặc dù số lượng tin đăng không phản ánh trực tiếp giá trị bất động sản, nhưng có thể xem đây là chỉ báo gián tiếp về mức độ quan tâm của thị trường đối với từng khu vực.

b. Phân tích giá bất động sản theo tình trạng pháp lý

Tình trạng pháp lý là một trong những yếu tố quan trọng ảnh hưởng đến tính thanh khoản cũng như mức độ an toàn của giao dịch bất động sản.




- Nhóm bất động sản có **Sổ đỏ** ghi nhận mức giá trung bình cao nhất, đạt 4,59 tỷ đồng. Đây là nhóm tài sản có tính pháp lý hoàn chỉnh, giúp người mua dễ dàng thực hiện các thủ tục chuyển nhượng, thế chấp hoặc vay vốn ngân hàng.
- Nhóm **Đang cập nhật** có giá trung bình 4,52 tỷ đồng. Mức giá này gần tương đương nhóm Sổ đỏ. Tuy nhiên cần lưu ý rằng đây là nhóm có quy mô dữ liệu

lớn nhất trong bộ dữ liệu khảo sát, do đó giá trị trung bình chịu ảnh hưởng bởi nhiều loại hình bất động sản khác nhau.

- Các bất động sản sở hữu **Sổ hồng** có giá trung bình 2,47 tỷ đồng, thấp hơn khoảng 2,12 tỷ đồng so với nhóm Sổ đỏ. Sự khác biệt này có thể xuất phát từ sự khác nhau về vị trí, quy mô diện tích và loại hình tài sản xuất hiện trong từng nhóm dữ liệu, chứ chưa đủ cơ sở để kết luận rằng Sổ đỏ luôn có giá trị cao hơn Sổ hồng.
- Nhóm HĐMB ghi nhận mức giá trung bình thấp nhất 1,50 tỷ đồng. Tuy nhiên số lượng quan sát của nhóm này rất nhỏ nên kết quả chỉ mang tính tham khảo và không đại diện cho toàn bộ thị trường.
- Nhận xét: kết quả cho thấy
 - Các bất động sản có hồ sơ pháp lý hoàn chỉnh (Sổ đỏ, Sổ hồng) thường duy trì mức giá tương đối cao.
 - Chênh lệch giá giữa các nhóm pháp lý tồn tại nhưng chưa quá lớn.
 - Pháp lý là yếu tố hỗ trợ hình thành giá trị tài sản, tuy nhiên tác động thực tế còn phụ thuộc mạnh vào vị trí, diện tích và loại hình bất động sản

c. Phân tích ảnh hưởng của hướng bất động sản đến giá trị tài sản

- Trong bộ dữ liệu nghiên cứu, hướng bất động sản được xem là một biến thuộc nhóm đặc điểm vật lý của tài sản. Mặc dù không trực tiếp tạo ra giá trị kinh tế như vị trí hay diện tích, hướng nhà có thể ảnh hưởng đến mức độ hấp dẫn của bất động sản thông qua các yếu tố về môi trường sống, khả năng thông gió, chiếu sáng tự nhiên và tâm lý lựa chọn của người mua.



- Biểu đồ cho thấy:
 - Hướng Tây có giá trung bình cao nhất với 5,55 tỷ đồng.
 - Hướng Nam và Đông gần như tương đương nhau.
 - Hướng Bắc có giá trung bình thấp nhất, khoảng 4,06 tỷ đồng.

Mức chênh lệch giữa hướng cao nhất và thấp nhất đạt $5,55 - 4,06 = 1,49$ (tỷ đồng)

d. Nhận xét tổng quan

- Kết quả phân tích cho thấy thị trường bất động sản Bình Định có sự khác biệt đáng kể về đặc điểm thông tin giữa các nhóm tài sản.
 - Hơn 54% tin đăng không công bố cụ thể tên đường, cho thấy mức độ thiếu đồng nhất về thông tin trên các nền tảng giao dịch.
 - Các tuyến đường như Nguyễn Thái Học, Hoàng Văn Thụ, Điện Biên Phủ và Trần Hưng Đạo là những khu vực xuất hiện nhiều tin đăng nhất, phản ánh mức độ sôi động của hoạt động giao dịch tại khu vực trung tâm.
 - Bất động sản có Sổ đỏ và nhóm đang cập nhật pháp lý ghi nhận mức giá trung bình cao nhất, lần lượt đạt 4,59 tỷ đồng và 4,52 tỷ đồng.
 - Hướng Tây có giá trị trung bình cao nhất (5,55 tỷ đồng) và cũng là nhóm có độ biến động lớn nhất, với các tài sản ngoại lệ đạt tới khoảng 25 tỷ đồng.
 - Tuy nhiên, sự chồng lấn đáng kể giữa các phân bố giá cho thấy hướng nhà và pháp lý chỉ là các yếu tố hỗ trợ, trong khi vị trí địa lý, quy mô diện tích và loại hình bất động sản vẫn là những biến số có khả năng tác động mạnh hơn đến giá trị tài sản trên thị trường Bình Định.

CHƯƠNG V. XÂY DỰNG, HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH DỰ ĐOÁN GIÁ BẤT ĐỘNG SẢN

1. Mở đầu và Thiết lập Môi trường Lập trình

Việc chuyển đổi từ phân tích mô tả (EDA) sang phân tích dự báo (Predictive Analytics) là bước đi chiến lược nhằm định lượng hóa các quy luật ngầm định của thị trường bất động sản Bình Định. Trong bối cảnh dòng vốn đầu tư đang đổ mạnh vào Quy Nhơn và các khu vực phụ cận như Phù Cát, Phù Mỹ, một mô hình học máy (Machine Learning) chính xác không chỉ giúp tối ưu hóa giá chào bán mà còn là công cụ quản trị rủi ro then chốt, thay thế cho phương thức định giá cảm tính truyền thống. Để đảm bảo tính tái lập (reproducibility) và tuân thủ các tiêu chuẩn kỹ thuật cao nhất, chúng tôi thiết lập hệ sinh thái Python chuyên dụng:

- **Pandas & Numpy:** Xử lý cấu trúc dữ liệu bảng và tính toán ma trận hiệu năng cao.
- **Scikit-learn:** Cung cấp khung sườn (framework) cho Pipeline, Preprocessing và các thuật toán hồi quy.
- **Matplotlib & Seaborn:** Trực quan hóa chẩn đoán mô hình và phân tích sai số.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split, GridSearchCV,
cross_val_score, learning_curve
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import RobustScaler, OneHotEncoder
from sklearn.linear_model import Ridge
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import r2_score, mean_absolute_error,
root_mean_squared_error
```

Việc thiết lập môi trường chuẩn hóa giúp loại bỏ các biến số nhiễu từ hạ tầng phần mềm, tạo nền móng vững chắc cho việc triển khai mô hình lên môi trường thực tế (Production-ready).

2. Xác định Biến mục tiêu (Target Variable Y)

Chúng tôi lựa chọn $gia(ty)$ làm biến mục tiêu thay vì đơn giá triệu/m². Đây là một quyết định mang tính chiến lược dựa trên đặc thù của thị trường Bình Định:

- **Sự nhất quán về mặt tuyến tính (Linear Consistency):** Diện tích là biến tương quan mạnh nhất với giá trị tổng. Trong khi đó, đơn giá (triệu/m²) tại Bình Định thường có quan hệ phi tuyến phức tạp. Diễn hình như tại khu vực Nhơn Hội, các lô đất diện tích cực lớn (đất mẫu) thường có đơn giá thấp hơn hẳn so với các lô nhỏ trong nội thành. Việc ép mô hình học một hàm số nghịch đảo và biến động dị biệt như vậy sẽ làm suy giảm chỉ số R^2 rõ rệt.

- **Triệt tiêu sai số tích lũy (Error Propagation):** Mục tiêu cuối cùng là định giá tổng tài sản. Nếu dự báo đơn giá rồi nhân với diện tích, một sai số nhỏ ở đơn giá (ví dụ 2 triệu/m²) sẽ bị phóng đại lên hàng trăm triệu khi nhân với diện tích lớn (200-500m²). Dự báo trực tiếp gia(ty) giúp kiểm soát sai số tổng trực tiếp và sát với thực tế giao dịch.

```
TARGET = "gia(ty)"
DANH_MUC_SO = [
    "dien_tich(m2)", "ngang (m)", "doc (m)", "so_tang", "so_phong_ngu", "so_wc",
    "dien_tich_hinh_hoc", "ty_le_khuon_dat", "tong_dien_tich_san", "tong_so_phong",
    "log_dien_tich", "log_dien_tich_san",
    "is_lo_goc", "is_mat_tien", "is_kinh_doanh", "is_ngop_cat_lo",
    "is_nha_moi_o_ngay",
    "don_gia_duong_encoded"]
DANH_MUC_CHU = [
    "nhom_bds", "quan_huyen", "huong", "phap_ly", "phan_khu",
    "nhom_tuyen_duong"]
```

Xác định xong biến mục tiêu, chúng ta cần làm giàu dữ liệu bằng các kỹ thuật đặc trưng nâng cao để mô hình "thấu hiểu" thị trường địa phương.

3. Kỹ thuật Đặc trưng Nâng cao (Advanced Feature Engineering)

Để mô hình nắm bắt được các yếu tố phi vật thể và cấu trúc hình học của bất động sản Quy Nhơn, chúng tôi thực hiện các biến đổi đặc trưng sau:

- **Đặc trưng Hình học & Quy mô:** `dien_tich_hinh_hoc` giúp phát hiện sai lệch khuôn đất; `ty_le_khuon_dat` đánh giá tính cân đối giữa ngang/dọc – yếu tố then chốt trong thẩm mỹ kiến trúc và giá trị thanh khoản; `tong_dien_tich_san` ước tính quy mô sử dụng thực tế.
- **Text Mining từ Tiêu đề:** Chúng tôi bóc tách các biến nhị phân mang tính "tâm lý thị trường". Đặc biệt là `is_ngop_cat_lo` (cắt lỗ, ngộp ngân hàng), giúp mô hình giải thích được tại sao một số tài sản có vị trí đẹp nhưng giá lại rẻ hơn 10-20% so với mặt bằng chung.

```
fe = df.copy()
fe["dien_tich_hinh_hoc"] = fe["ngang (m)"] * fe["doc (m)"]
fe["ty_le_khuon_dat"] = (fe["ngang (m)"] / fe["doc (m)"].replace(0, np.nan)).fillna(0).clip(0, 5)
fe["tong_dien_tich_san"] = fe["dien_tich(m2)"] * fe["so_tang"].clip(lower=1)
fe["tong_so_phong"] = fe["so_phong_ngu"] + fe["so_wc"]
fe["log_dien_tich"] = np.log1p(fe["dien_tich(m2)"])
fe["log_dien_tich_san"] = np.log1p(fe["tong_dien_tich_san"])
fe['tieu_de_clean'] = fe['tieu_de'].fillna('').str.lower()
fe['is_lo_goc'] = fe['tieu_de_clean'].str.contains('lô góc|2 mặt tiền|hai mặt tiền',
regex=True).astype(int)
fe['is_mat_tien'] = (fe['tieu_de_clean'].str.contains('mặt tiền|mặt phố', regex=True) &
(fe['is_lo_goc'] == 0)).astype(int)
```

```
fe['is_kinh_doanh'] = fe['tieu_de_clean'].str.contains('kinh doanh|buôn bán|cho thuê',
regex=True).astype(int)
fe['is_ngop_cat_lo'] = fe['tieu_de_clean'].str.contains('cắt lỗ|ngộp|bán gấp|hạ giá',
regex=True).astype(int)
fe['is_nha_moi_o_ngay'] = fe['tieu_de_clean'].str.contains('mới xây|vào ở ngay|full nội
thất', regex=True).astype(int)
```

Sau khi làm giàu đặc trưng, bước tiếp theo là xây dựng quy trình tiền xử lý tự động để chuẩn hóa dữ liệu trước khi huấn luyện.

4. Pipeline Tiền xử lý Dữ liệu Sạch (Preprocessing Pipeline)

Một thách thức lớn trong dữ liệu Bình Định là sự tồn tại của 138 tên đường khác nhau. Nếu sử dụng trực tiếp OneHotEncoder cho tên đường, mô hình sẽ rơi vào tình trạng **Overfitting (học vẹt)** do ma trận dữ liệu quá thưa (Sparse Matrix). Chúng tôi giải quyết bằng cách gom 138 con đường thành các biến phân_khu chiến lược (Quy Nhơn Mới, Đông, Nam, Bắc) và nhóm_tuyen_duong để giảm chiều dữ liệu.

Ngoài ra, chúng tôi áp dụng **Target Encoding** cho đơn giá đường (don_gia_duong_encoded). Lưu ý kỹ thuật: Chỉ sử dụng **trung vị (median)** từ **tập huấn luyện (Training Set)** để tính toán, sau đó ánh xạ sang tập Test. Điều này ngăn chặn hiện tượng **Data Leakage (Rò rỉ dữ liệu)**, tránh việc mô hình "biết trước" đáp án của tập kiểm tra.

Trong kiến trúc ColumnTransformer, chúng tôi ưu tiên RobustScaler:

Đặc điểm	StandardScaler	RobustScaler (Lựa chọn tối ưu)
Cơ sở chuẩn hóa	Trung bình & Độ lệch chuẩn	Trung vị & Khoảng tứ phân vị (IQR)
Khả năng chống nhiễu	Kém, bị ảnh hưởng bởi Outliers	Rất tốt (Robust)
Lý do áp dụng	Phù hợp dữ liệu phân phối chuẩn	Chống nhiễu từ các biệt thự biển hoặc tòa nhà cao tầng có giá dị biệt

Chúng tôi cũng thiết lập ngưỡng chặn đơn giá (Price Ceiling) tại **290 triệu/m²** dựa trên thực tế thị trường để loại bỏ các tin đăng ảo.

```
preprocessor = ColumnTransformer([
    ("num", RobustScaler(), DANH_MUC_SO),
    ("cat", OneHotEncoder(handle_unknown="ignore", sparse_output=False),
    DANH_MUC_CHU)
], remainder="drop")
```

Kiến trúc này đảm bảo Pipeline vận hành ổn định ngay cả khi gặp các địa danh lạ trong tương lai thông qua tham số handle_unknown="ignore".

5. Huấn luyện Mô hình Baseline (Cross-Validation 5-Fold)

Chúng tôi áp dụng kỹ thuật đánh giá chéo 5-Fold để đo lường khả năng tổng quát hóa. Trước khi huấn luyện, biến mục tiêu được chuyển sang thang đo Log (np.log1p) để thu hẹp khoảng cách giữa các phân khúc giá. Nghiên cứu so sánh hai triết lý thuật toán:

- **Ridge Regression:** Mô hình tuyến tính, đánh giá mức độ tương quan trực tiếp.

- **Random Forest:** Mô hình phi tuyến dựa trên cây, có khả năng nắm bắt các tương tác phức tạp.

```
y_train_log = np.log1p(y_train)
pipe_ridge_base = Pipeline([("prep", preprocessor), ("ridge", Ridge(alpha=10.0))])
pipe_rf_base = Pipeline([("prep", preprocessor), ("rf", RandomForestRegressor(random_state=42, n_jobs=-1))])
cv_r2_ridge = cross_val_score(pipe_ridge_base, X_train, y_train_log, cv=5, scoring="r2").mean()
cv_r2_rf_base = cross_val_score(pipe_rf_base, X_train, y_train_log, cv=5, scoring="r2").mean()
```

Kết quả Baseline:

-> [Baseline] Ridge Regression 5-Fold CV R^2 : 0.7778

-> [Baseline] Random Forest 5-Fold CV R^2 : 0.7824

Ridge đạt $R^2 \sim 0.7778$, trong khi Random Forest nhỉnh hơn với $R^2 \sim 0.7824$. Ưu thế của Random Forest nằm ở việc xử lý các đặc trưng phi tuyến từ vị trí địa lý tốt hơn.

6. Xác định và Trục quan hóa Tầm quan trọng của Đặc trưng

Phân tích "bộ não" của Random Forest cung cấp những góc nhìn giá trị về "Location Premium" (phần bù vị trí) tại Bình Định:

- **so_wc:** Đây là biến có trọng số cao nhất. Trong thực tế thị trường địa phương, số lượng nhà vệ sinh là **biến đại diện (proxy)** cho quy mô xây dựng và công năng khai thác của bất động sản.
- **don_gia_duong_encoded:** Xác nhận rằng đẳng cấp tuyến đường (đặc biệt là các cung đường ven biển như Xuân Diệu, An Dương Vương) quyết định phần lớn giá trị tài sản.
- **is_lo_goc & dien_tich:** Khẳng định giá trị thặng dư của các vị trí đắc địa và quy mô diện tích thực.

Mô hình đã thành công trong việc nắm bắt cấu trúc định giá thực tế: ưu tiên vị trí và công năng sử dụng hơn là các yếu tố cảm tính. Tiếp theo, chúng ta cần tối ưu hóa các tham số để đạt hiệu suất cao nhất.

7. Tối ưu hóa với GridSearchCV (Giảm thiểu Overfitting)

Để cân bằng giữa độ khớp và khả năng tổng quát hóa, chúng tôi tinh chỉnh các tham số siêu hình thông qua GridSearchCV. Mục tiêu là kiểm soát độ sâu của cây để tránh "học thuộc lòng" dữ liệu nhiều.

```
param_grid = {
    "rf__n_estimators": [300, 500],
    "rf__max_depth": [12, 15],
    "rf__min_samples_leaf": [2, 4],
    "rf__max_features": [0.4, "sqrt"]
}
grid_search = GridSearchCV(pipe_rf_base, param_grid, cv=5, scoring="r2", n_jobs=-1)
print("Đang quét tìm cấu hình tối ưu để triệt tiêu hiện tượng Overfitting...")
```

```
grid_search.fit(X_train, y_train_log)
```

Kết quả tối ưu xác định cấu hình: $\text{max_depth}=12$ và $\text{n_estimators}=500$. Cấu hình này giúp mô hình đạt điểm CV R^2 ổn định nhất trên không gian Log.

8. Xây dựng Mô hình Random Forest Tối ưu và Dự đoán thực tế


Dựa trên cấu hình đã tìm được, chúng tôi xây dựng mô hình cuối cùng. Một bước bắt buộc là sử dụng hàm `np.expm1()` để chuyển đổi dự báo từ thang đo Log về đơn vị "Tỷ đồng" thực tế.

```
bo_tham_so_toi_uu = {
    "n_estimators": 500,
    "max_depth": 12,
    "max_features": 0.4,
    "random_state": 42 }
pipe_rf_tuned = Pipeline([
    ("prep", preprocessor),
    ("rf", RandomForestRegressor(**bo_tham_so_toi_uu, n_jobs=-1))]
)
pipe_rf_tuned.fit(X_train, y_train_log)
y_pred_rf_tuned = np.expm1(pipe_rf_tuned.predict(X_test))
```

9. Đồ thị Chẩn đoán và Bảng so sánh Hiệu năng Tổng hợp

Hiệu năng của mô hình được kiểm chứng qua 3 loại đồ thị:

- **Learning Curve:** Hai đường Train và Validation hội tụ tại mức R^2 cao, chứng tỏ mô hình đã "học" được quy luật thay vì học vẹt.
- **Residual Plot:** Các sai số phân bố ngẫu nhiên quanh trục 0. Tuy nhiên, xuất hiện hiện tượng **Heteroscedasticity (Phương sai sai số thay đổi)** ở phân khúc trên 10 tỷ. Điều này phản ánh thực tế rằng ở phân khúc cao cấp, giá cả bị chi phối bởi các yếu tố "vô hình" như nội thất xa xỉ hoặc tâm lý đàm phán của chủ nhà.
- **Actual vs. Predicted:** Các điểm dữ liệu tập trung sát đường $y=x$, minh chứng cho độ khớp cao của dự báo.



Bảng so sánh hiệu năng tổng hợp:

Kiến trúc Mô hình	CV R^2 (5-Fold)	Test R^2 (Hold-out)	MAE (Tỷ)	RMSE (Tỷ)
Ridge Regression (Baseline)	0.7778	0.7031	1.192	2.051
Random Forest Baseline	0.7824	0.7679	1.048	1.813
Random Forest Tuned	0.7794	0.7799	1.005	1.766

Mô hình **Random Forest Tuned** đạt chỉ số Test R^2 xấp xỉ **0.78**. Mức sai số MAE khoảng **1.0 tỷ đồng** là hoàn toàn chấp nhận được và phản ánh đúng biên độ dao động giá tại thị trường Quy Nhơn – nơi một quyết định đàm phán có thể làm thay đổi giá trị hàng tỷ đồng.

CHƯƠNG VI. KẾT LUẬN

1. Tổng kết và Đánh giá Kết quả Nghiên cứu

Dưới góc độ chiến lược, việc chuyển đổi các tệp dữ liệu thô từ nền tảng số thành các chỉ số thị trường minh bạch không chỉ đơn thuần là bài toán kỹ thuật mà còn là nền tảng cốt yếu để chuẩn hóa thị trường bất động sản Bình Định. Báo cáo này đã thiết lập một hệ thống phân tích thực chứng, đi từ quy trình thu thập dữ liệu diện rộng đến việc xây dựng mô hình dự báo có khả năng định lượng các quy luật ngầm định của thị trường địa phương.

- **Giá trị dữ liệu hệ thống:** Chiến lược phân tích dựa trên tập mẫu gồm **767 quan sát** thực tế, được chuẩn hóa thông qua pipeline xử lý dữ liệu nghiêm ngặt. Điểm đột phá về mặt kỹ thuật nằm ở việc ứng dụng Text Mining để trích xuất thực thể từ các tiêu đề tin đăng phi cấu trúc. Việc chuyển đổi các từ khóa thành các biến số nhị phân như `is_ngop_cat_lo` (áp lực tài chính/cắt lỗ) và `is_lo_goc` đã cho phép mô hình thấu hiểu được các tín hiệu tâm lý và "phần bù vị trí" vốn thường bị bỏ qua trong các phương pháp thống kê truyền thống.
- **Đặc trưng thị trường qua lăng kính dữ liệu:** Dữ liệu xác nhận một sự phân hóa sâu sắc về giá trị dựa trên loại hình tài sản và tọa độ địa lý. "Lớp thặng dư" của bất động sản xây sẵn so với đất thô được minh chứng rõ nét qua đơn giá đơn vị.

Chỉ số đặc trưng	Nhóm Nhà	Nhóm Đất	Ghi chú chiến lược
Số lượng quan sát	337 mẫu	430 mẫu	Phân bổ mẫu cân bằng, đảm bảo tính đại diện.
Đơn giá trung bình	59.06 triệu/m ²	24.79 triệu/m ²	Giá trị xây dựng và thương mại tạo thặng dư gấp 2.38 lần.
Giá trị tài sản TB	4.95 tỷ VNĐ	2.92 tỷ VNĐ	Quy Nhơn dẫn đầu về "Location Premium".
Khu vực tiêu biểu	Quy Nhơn, Phù Mỹ	Phù Cát, Phù Mỹ	Phù Mỹ dẫn đầu về quy mô giá trị do diện tích lô đất lớn.

Lưu ý: Phân tích xác nhận rằng trong khi Quy Nhơn giữ vị thế cao về đơn giá nhờ lợi thế vị trí, thì Huyện Phù Mỹ đạt mức giá trung bình cao nhất (5.20 tỷ VNĐ) chủ yếu do "quy mô tài sản vật lý" (diện tích các lô đất hoặc tài sản lớn hơn mức trung bình).

- **Hiệu năng mô hình dự báo:** Mô hình **Random Forest Tuned** đã khẳng định vị thế là một công cụ dự báo đáng tin cậy với chỉ số $R^2 \approx 0.78$ (chính xác là 0.7799 trên tập kiểm thử). Điều này đồng nghĩa với việc mô hình giải thích được gần 78% sự biến thiên giá trị trong thực tế. Sai số tuyệt đối trung bình (MAE) duy trì ở mức **1.0 tỷ đồng**. Trong bối cảnh thị trường Bình Định thường xuyên có biên độ đàm phán rộng, con số 1.0 tỷ này không đơn thuần là sai số kỹ thuật mà nên được nhìn nhận như một "vùng đệm đàm phán" (negotiation buffer) thực tế giữa người mua và người bán.

Mặc dù mô hình đạt hiệu suất ấn tượng, các nhà hoạch định chiến lược cần nhận diện rõ những điểm nghẽn về tính minh bạch để tối ưu hóa khả năng ứng dụng thực tiễn.

2. Các Hạn chế và Thách thức trong Quá trình Triển khai

Trong khoa học dữ liệu bất động sản, việc thừa nhận các hạn chế không phải là sự thừa nhận thất bại, mà là bước đi cần thiết để xác định phạm vi áp dụng và mức độ tin cậy của mô hình dự báo. Trong quá trình thực hiện đề tài, nhóm nghiên cứu đã gặp phải một số khó khăn và thách thức đáng chú ý như sau:

- **Hạn chế về tính minh bạch và bất đối xứng thông tin:** Thách thức lớn nhất hiện nay là sự thiếu hụt thông tin vị trí vi mô. Một tỷ lệ đáng kể các tin đăng không cung cấp đầy đủ tên đường hoặc vị trí cụ thể của bất động sản. Điều này gây khó khăn trong việc lượng hóa ảnh hưởng của vị trí đến giá bán, trong khi đây lại là một trong những yếu tố quan trọng nhất của thị trường bất động sản. Trên thực tế, chỉ cần khác biệt về vị trí mặt tiền, hẻm, khoảng cách đến trung tâm hoặc các tuyến giao thông chính cũng có thể làm giá trị bất động sản chênh lệch rất lớn. Do đó, việc thiếu thông tin địa chỉ chi tiết khiến mô hình chưa thể khai thác hết sức mạnh của yếu tố vị trí, dẫn đến sai số dự báo cao hơn đối với một số trường hợp cụ thể.
- **Khó khăn trong quá trình thu thập dữ liệu:** Công đoạn thu thập dữ liệu (Web Scraping) là một trong những phần khó khăn nhất của đề tài. Nhóm nghiên cứu chưa có nhiều kinh nghiệm thực tế với các công cụ thu thập dữ liệu tự động, đồng thời phải làm việc với các website có cấu trúc dữ liệu phức tạp và thường xuyên thay đổi. Bên cạnh đó, các nền tảng bất động sản hiện nay đều áp dụng nhiều cơ chế chống thu thập dữ liệu tự động như giới hạn truy cập, phát hiện bot hoặc các lớp bảo vệ như Cloudflare. Điều này làm tăng đáng kể thời gian xây dựng và hiệu chỉnh chương trình thu thập dữ liệu, đồng thời tạo ra nguy cơ dữ liệu bị thiếu hoặc không được cập nhật đầy đủ khi hệ thống chống bot thay đổi.
- **Hạn chế về quy mô và mức độ đầy đủ của dữ liệu:** Do giới hạn về thời gian thực hiện đề tài và khả năng thu thập dữ liệu, tập dữ liệu hiện tại mới chỉ phản ánh một phần thị trường bất động sản Bình Định trong một khoảng thời gian

nhất định. Một số khu vực có số lượng tin đăng còn ít hoặc thiếu các thuộc tính quan trọng như tên đường, hướng nhà, số tầng hoặc tình trạng pháp lý. Điều này khiến mô hình chưa học được đầy đủ đặc trưng của tất cả các phân khúc bất động sản trên thị trường. Đặc biệt, trong quá trình triển diễn và kiểm thử mô hình, nhóm nhận thấy một số trường hợp dự đoán chưa chính xác xuất phát từ việc bất động sản không có thông tin tên đường hoặc vị trí chi tiết. Khi thiếu các đặc trưng mang tính quyết định này, mô hình buộc phải dựa trên các thuộc tính còn lại để đưa ra dự báo, dẫn đến sai số lớn hơn so với mong đợi.

- **Thách thức trong xử lý dữ liệu ngoại lai:** Dữ liệu bất động sản thường tồn tại nhiều giá trị ngoại lai, đặc biệt ở phân khúc cao cấp hoặc các bất động sản có vị trí đặc biệt. Việc xử lý ngoại lai là một bài toán đánh đổi giữa chất lượng dữ liệu và khả năng học của mô hình. Nếu loại bỏ quá nhiều giá trị ngoại lai, bộ dữ liệu sẽ trở nên "sạch" hơn nhưng đồng thời làm mất đi những trường hợp giá trị cao có thật trên thị trường. Ngược lại, nếu giữ nguyên toàn bộ dữ liệu ngoại lai, các mô hình dự báo có thể bị ảnh hưởng bởi các điểm dữ liệu cực đoan, dẫn đến hiện tượng học lệch. Trong quá trình thực nghiệm, nhóm nhận thấy việc lọc ngoại lai quá mạnh có thể làm giảm độ chính xác tổng thể của mô hình do làm mất thông tin của một số bất động sản giá trị cao. Vì vậy, nhóm phải cân bằng giữa việc loại bỏ các giá trị bất thường do lỗi dữ liệu và việc giữ lại những bất động sản cao cấp có giá trị thực tế.
- **Hiện tượng Heteroscedasticity và đặc thù của phân khúc cao cấp:** Mô hình hiện tại hoạt động tốt đối với phần lớn các bất động sản thuộc phân khúc phổ thông và trung cấp. Tuy nhiên, khi áp dụng cho nhóm bất động sản có giá trị rất cao, sai số dự báo có xu hướng gia tăng. Nguyên nhân là do giá trị của các bất động sản cao cấp không chỉ phụ thuộc vào diện tích, số tầng hay vị trí địa lý, mà còn chịu ảnh hưởng của nhiều yếu tố khó định lượng như chất lượng nội thất, giá trị thương hiệu khu vực, tiềm năng đầu tư, yếu tố phong thủy hoặc tâm lý thương lượng giữa người mua và người bán. Đây là những yếu tố chưa được phản ánh đầy đủ trong bộ dữ liệu hiện tại.

3. Định hướng và Hướng phát triển Tương lai

Để duy trì lợi thế cạnh tranh trong kỷ nguyên AI và Big Data, dự án cần tiến hóa từ một báo cáo phân tích tĩnh thành một hệ sinh thái dữ liệu động, phục vụ cho mục tiêu minh bạch hóa toàn diện thị trường Bình Định.

- **Làm giàu dữ liệu và Chuyển đổi không gian (GIS):** Bước đột phá tiếp theo là tích hợp dữ liệu không gian (GIS). Thay vì dựa vào địa chỉ văn bản vốn đầy sai lệch, việc chuyển sang hệ tọa độ địa lý chính xác sẽ là chìa khóa để mở khóa độ chính xác ở cấp độ vi mô. Đồng thời, việc tích hợp chuỗi dữ liệu lịch sử giá sẽ cho phép triển khai các phân tích chuỗi thời gian (Time-series analysis), giúp dự báo xu hướng thay vì chỉ định giá tại một thời điểm.
- **Nâng cấp thuật toán và Tự động hóa quy trình:** Để xử lý các mối quan hệ phi tuyến tính phức tạp ở phân khúc hạng sang, việc thử nghiệm các mô hình Ensemble Learning chuyên sâu như **XGBoost** hoặc **LightGBM** là hướng đi tất

yếu. Ngoài ra, cần tự động hóa các kỹ thuật như *Target Encoding* và *RobustScaler* vào một pipeline dữ liệu thời gian thực để ngăn chặn triệt để hiện tượng rò rỉ dữ liệu (Data Leakage).

- **Kiến tạo Hệ thống Định giá Tự động (AVM):** Mục tiêu cuối cùng là xây dựng ứng dụng **AVM (Automated Valuation Model)** dành riêng cho Bình Định. Hệ thống này không chỉ cung cấp giá trị tham chiếu tức thì mà còn tích hợp các chỉ số về biến động thời gian, hỗ trợ nhà đầu tư và người dân giảm thiểu rủi ro "mua hớ, bán hớ".

Sự hội tụ giữa năng lực Khoa học dữ liệu hiện đại và sự am hiểu sâu sắc về thị trường địa phương chính là chìa khóa để kiến tạo một môi trường bất động sản bền vững, minh bạch và chuyên nghiệp tại Bình Định.

PHỤ LỤC

Link Github: <https://github.com/trinhtran2805/nhom1-bds-binhdingh>